Documentação
Atividade de análise de voos

2CCO – São Paulo Tech Schoool

Grupo 02:

Diego- 04241019

Ivan- 04241013

Gustavo- 04241034

Gisele- 04241052

Luis- 04241047

Vitor- 04141059

[Sumário]

Tratamento

1 - Preparação e Carregamento dos Dados:

Importação de Bibliotecas: O script importa bibliotecas essenciais para manipulação de arquivos, dados e conexão com a AWS. As principais são:

- **pandas** para manipulação e análise de dados em DataFrames.
- **os** para interagir com o sistema de arquivos local.
- **boto3** para se conectar e gerenciar recursos na AWS.
- **win32com.client** para automação de tarefas com arquivos Microsoft (neste caso, Excel).

Conversão de Arquivo XLS: A função converter_xls_para_xlsx usa a biblioteca win32com para abrir um arquivo .xls e salvá-lo como .xlsx. Isso é necessário para que a biblioteca pandas possa ler o arquivo, já que o formato .xls é mais antigo e pode causar problemas de compatibilidade.

2. Tratamento e Padronização de Dados:

Tratamento do dataset de Aeroportos e Empresas Aéreas:

- Os arquivos aerodromospublicos.xlsx e Empresas Aereas.xlsx são carregados em DataFrames.
- **Limpeza de Nomes de Colunas**: Os nomes das colunas são padronizados para ficarem em letras maiúsculas, sem acentos e com espaços substituídos por sublinhados (_), por exemplo, "NOME FANTASIA" se torna "NOME_FANTASIA".
- **Limpeza de Dados Textuais**: A função remover_acentos é aplicada a todas as colunas de texto (object), garantindo que o conteúdo também seja padronizado.
- **Conversão de Coordenadas**: A função extrair_dms utiliza uma expressão regular (re) para extrair os valores de graus, minutos, segundos e a direção (N, S, W, E) de uma string de coordenadas, como 8° 20' 55'' S. Em seguida, a função dms_para_dd converte esses valores para o formato de graus decimais, que é mais fácil de ser usado para cálculos geográficos.
- **Filtro por Tipo de Voo**: Os dados de empresas aéreas são filtrados para incluir apenas as que operam voos domésticos.

Tratamento do dataset de Reclamações:

- **O arquivo dadosconsumidor2024**.csv é lido, usando ponto e vírgula como separador.
- **Limpeza de Colunas e Dados**: A função limpar_texto é aplicada para padronizar os nomes das colunas e o conteúdo textual.
- **Conversão de Datas**: As colunas de data são identificadas e convertidas para o formato dd/mm/yyyy ou dd/mm/yyyy hh:mm:ss, garantindo que sejam reconhecidas corretamente.
- **Filtro por Assunto**: Os dados são filtrados para manter apenas as reclamações relacionadas a "TRANSPORTES" com o "ASSUNTO" "AEREO".

Tratamento do dataset de Voos:

- **O arquivo VRA_2024.csv é lido**. O script limita a leitura a 100.000 linhas para otimizar o processamento e a demonstração.
- **Limpeza e Conversão de Tipos**: O mesmo processo de padronização de colunas e dados é aplicado. As colunas de datas e horas são convertidas para o formato dd/mm/yyyy hh:mm:ss.
- **Filtragem de Voos Domésticos:** Os dados são filtrados para incluir apenas voos domésticos. Isso é feito verificando se os códigos ICAO (SIGLA_ICAO_AEROPORTO_ORIGEM e SIGLA_ICAO_AEROPORTO_DESTINO) começam com 'SB', que é o padrão para aeroportos brasileiros.

Particionamento

- **Converte a coluna de data** para um tipo de dado datetime, o que permite a extração de informações como ano e mês de forma programática.
- **Cria uma nova coluna ANO_MES** com o ano e o mês (por exemplo, 202405 para maio de 2024), que serve como chave para o particionamento.
- **Salva os dados** de cada mês em um arquivo .csv separado, garantindo que os dados fiquem organizados em uma estrutura de diretórios eficiente. Por exemplo, os dados de janeiro de 2024 de reclamações seriam salvos em dados/trusted/reclamacoes/reclamacao_202401.csv.

Armazenamento

1. Estrutura de Armazenamento

A base da arquitetura é a organização dos dados em três buckets S3 na AWS, cada um correspondendo a um estágio de tratamento:

- **Raw**: Contém os dados brutos, exatamente como foram obtidos da fonte original.
- **Trusted**: Armazena os dados que foram limpos, padronizados e estão prontos para uso.
- **Refined**: Destinado a dados que passaram por processamento analítico, como agregações ou transformações que os tornam prontos para dashboards e relatórios.

A infraestrutura para esses buckets e suas "pastas" virtuais foi criada usando **Terraform** e está disponível através do arquivo **main.tf.**

2. Envio de Dados

- **Envio para bucket Raw**: O script **envio_bucket.py** realiza o carregamento de todos os dados locais para o bucket raw da AWS para futuro tratamento ao mesmo tempo que preserva a estrutura original dos dados
- **Envio para bucket Trusted**: Já o envio para o bucket Trusted é feito pelo mesmo script onde ocorre o tratamento de dados, o script **tratamento.py**, usamos o mesmo arquivo para possível futuro armazenamento e automatização dos tratamentos usando um lambda ou Trigger.

Arquitetura de Solução

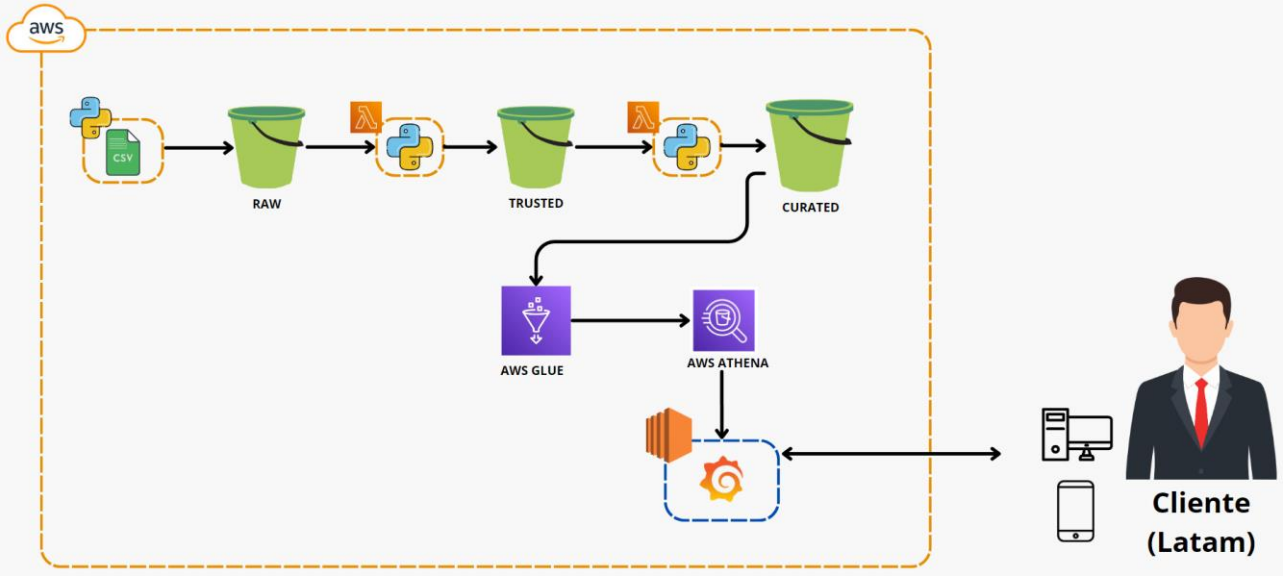

Refinamento de Dados

Durante a segunda parte da atividade foi definido que a análise de dados terá foco em auxiliar a companhia aérea **LATAM AIRLINES BRASIL**. Com o objetivo de preparar os dados para a criação de gráficos foram feitos novos tratamentos nos dados para o envio para o bucket **refined**, foram adicionadas as colunas **cluster_hora** e os arquivos foram filtrados pela cidade e estado de **São Paulo** para a cidade e estado do **Rio de Janeiro**, foi feita a junção do dataset de aeroportos com o dataset de voos, alterando a modelagem para **Flattened** adicionando dados de cidade, estado, latitude e longitude dos aeroportos. Além da criação de tabelas sumarizadas para auxiliar o **Grafana** na criação de gráficos. Todos os resultados estão disponíveis no arquivo zip enviado e no github, o arquivo usado para essa finalidade foi o **03_refined.py**.

Análise exploratória

No arquivo **04_analise_exploratoria.ipynb** foi feita uma análise exploratória com o intuito de definir a melhor forma de dispor os dados.

Resultados obtidos

Dashboard de voos

Snapshot da dashboard de voos:
https://snapshots.raintank.io/dashboard/snapshot/JbEgb0TEvCMQA955PHGKa3OK4LZsBdTp

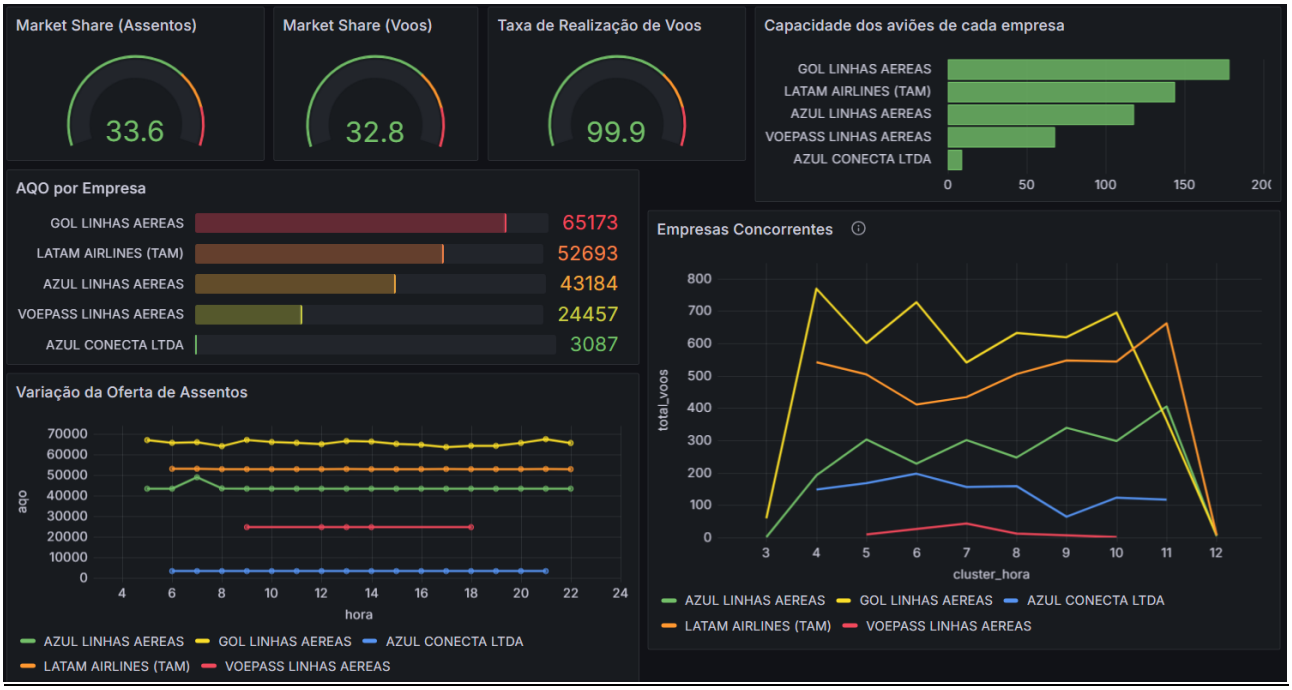

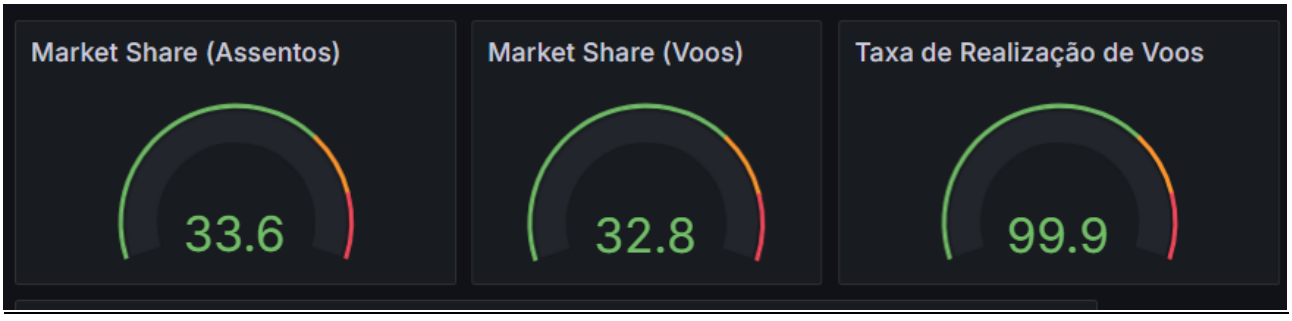

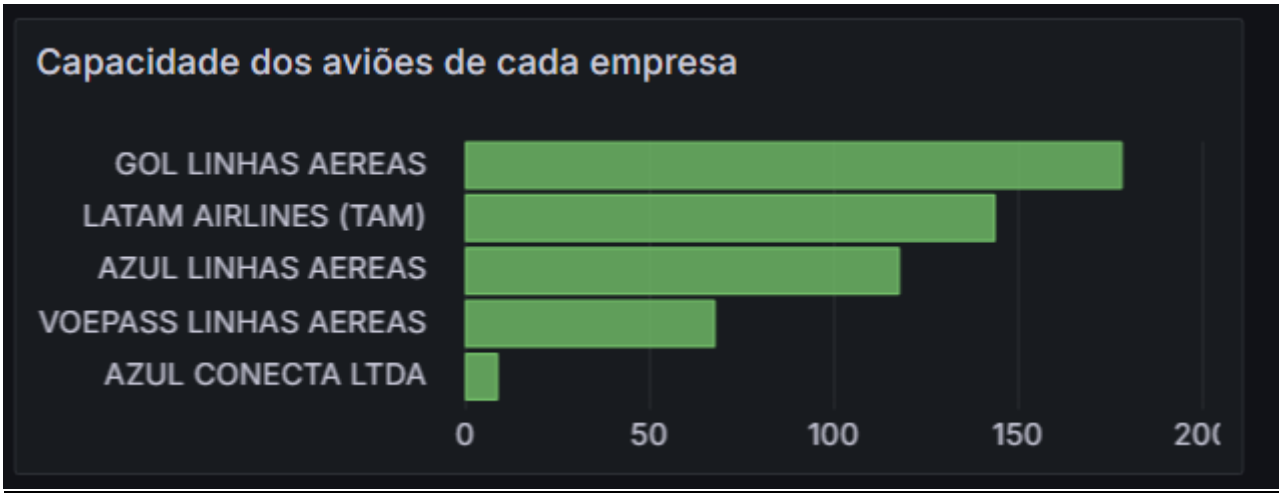
Capacidade dos aviões de cada empresa
GOL LINHAS AEREAS
LATAM AIRLINES (TAM)
AZUL LINHAS AEREAS
VOEPASS LINHAS AEREAS
AZUL CONECTA LTDA
0
50
100
150
200

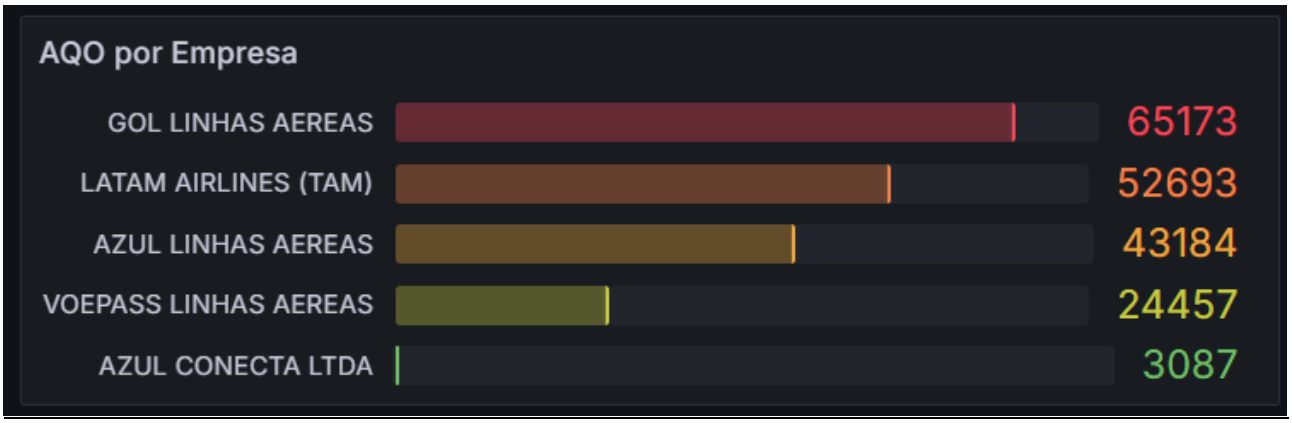
AQO por Empresa
GOL LINHAS AEREAS
65173
LATAM AIRLINES (TAM)
52693
AZUL LINHAS AEREAS
43184
VOEPASS LINHAS AEREAS
24457
AZUL CONECTA LTDA
3087

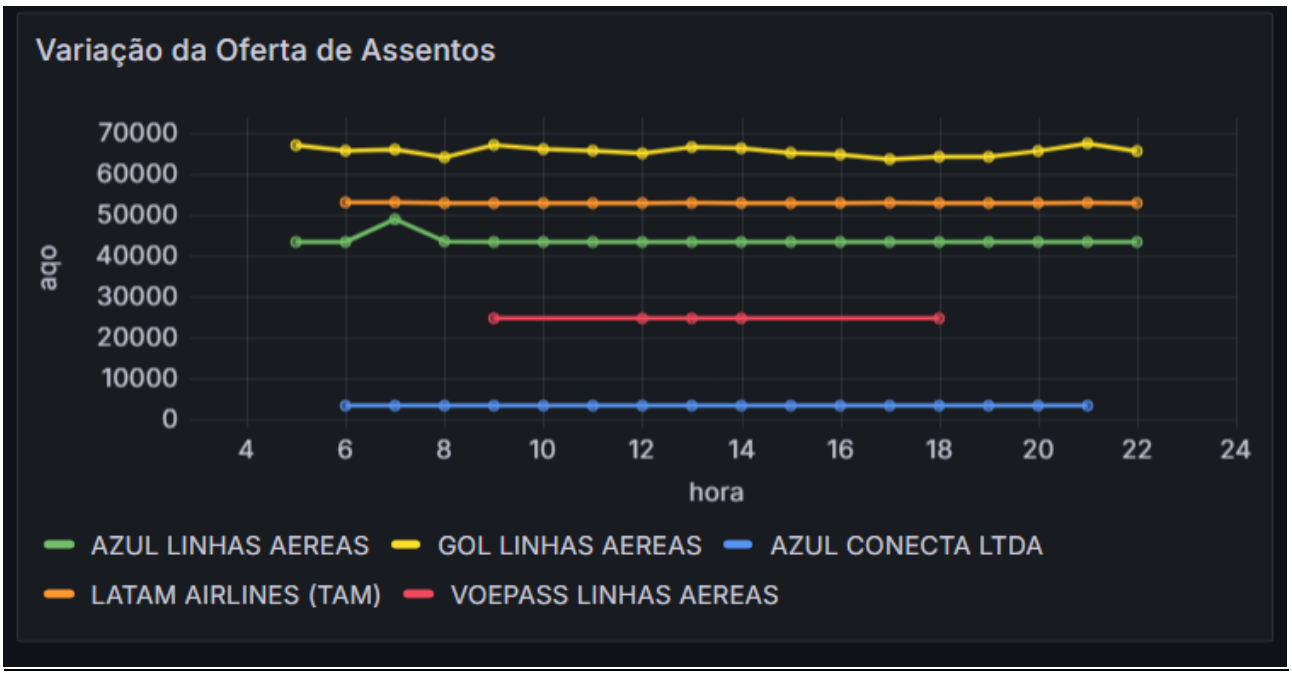
Variação da Oferta de Assentos
70000
60000
50000
40000
30000
20000
10000
0
aqo
4
6
8
10
12
14
16
18
20
22
24
hora
AZUL LINHAS AEREAS
GOL LINHAS AEREAS
AZUL CONECTA LTDA
LATAM AIRLINES (TAM)
VOEPASS LINHAS AEREAS

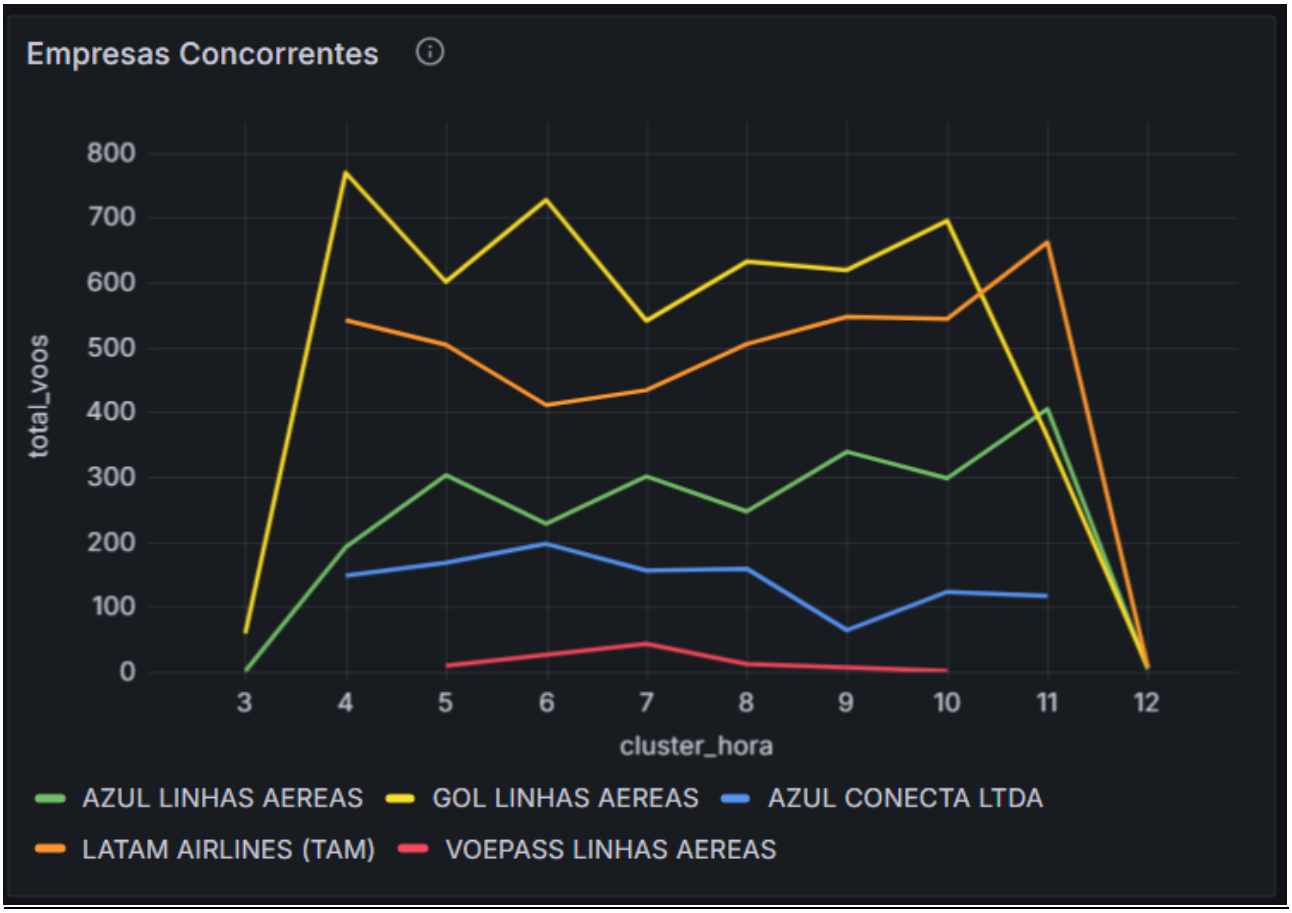

Dashboard de reclamações

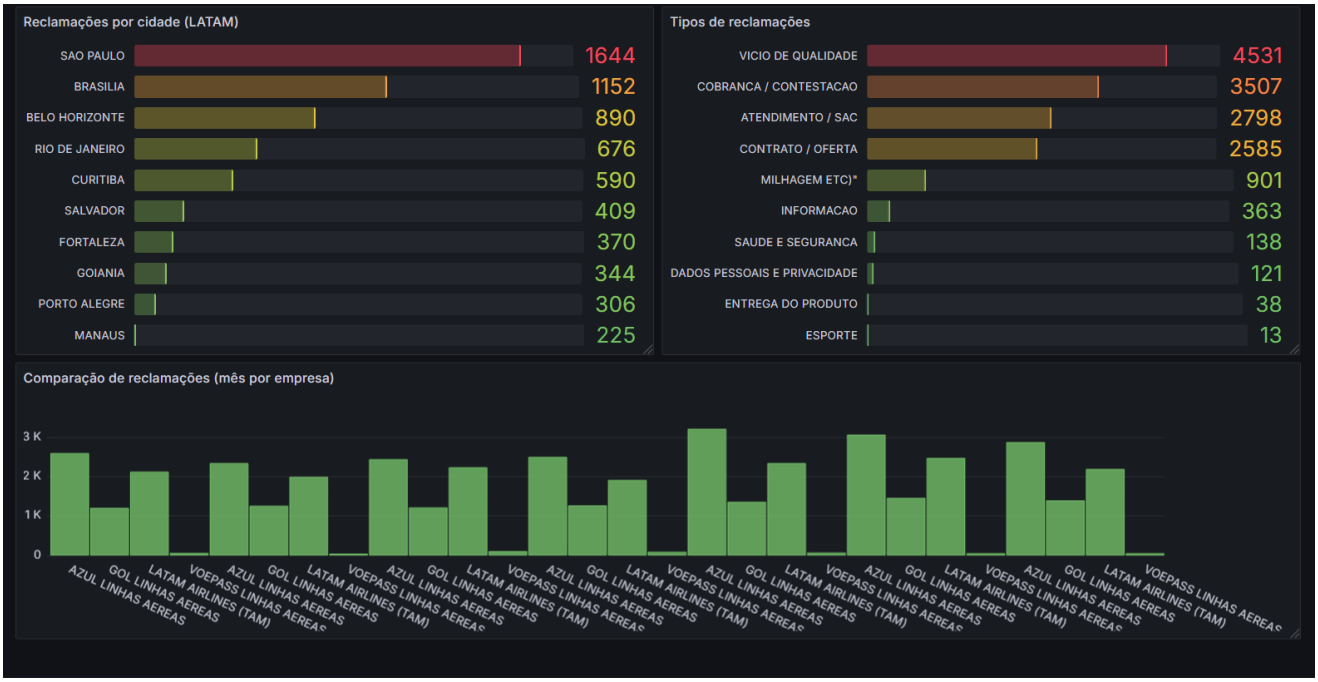

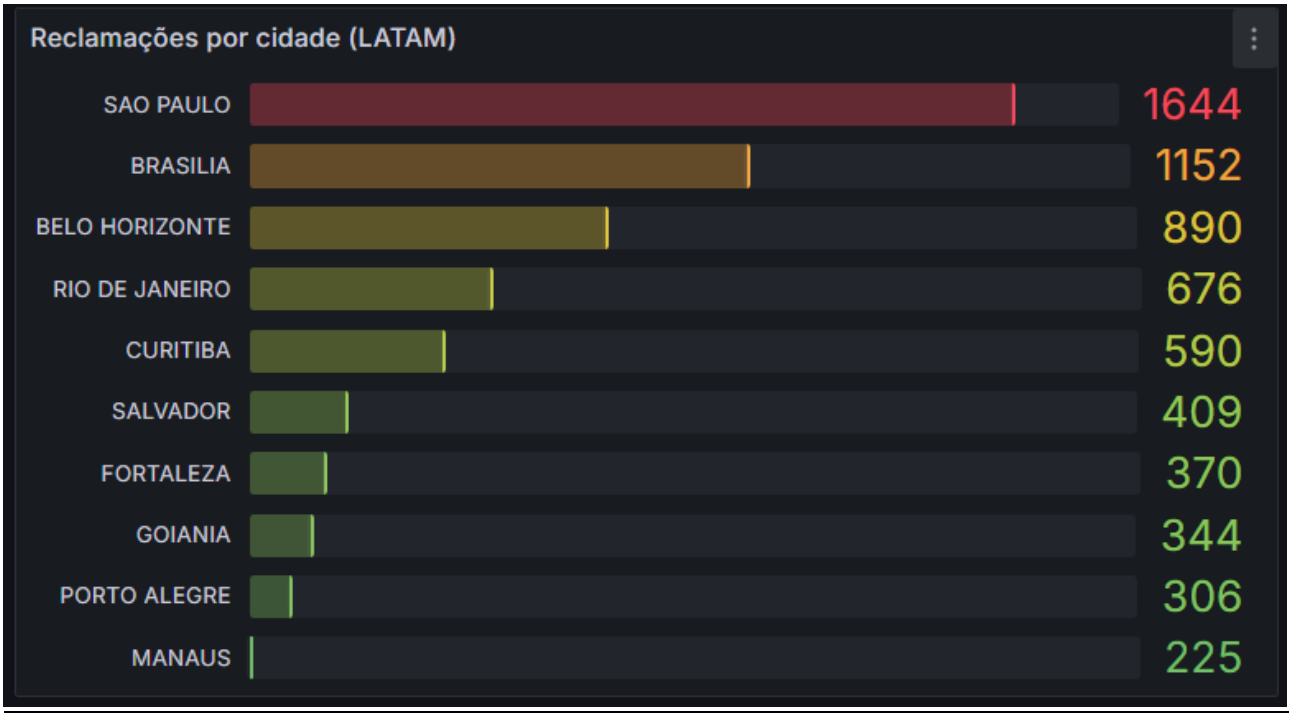
Reclamações por cidade (LATAM)
SAO PAULO 1644
BRASILIA 1152
BELO HORIZONTE 890
RIO DE JANEIRO 676
CURITIBA 590
SALVADOR 409
FORTALEZA 370
GOIANIA 344
PORTO ALEGRE 306
MANAUS 225

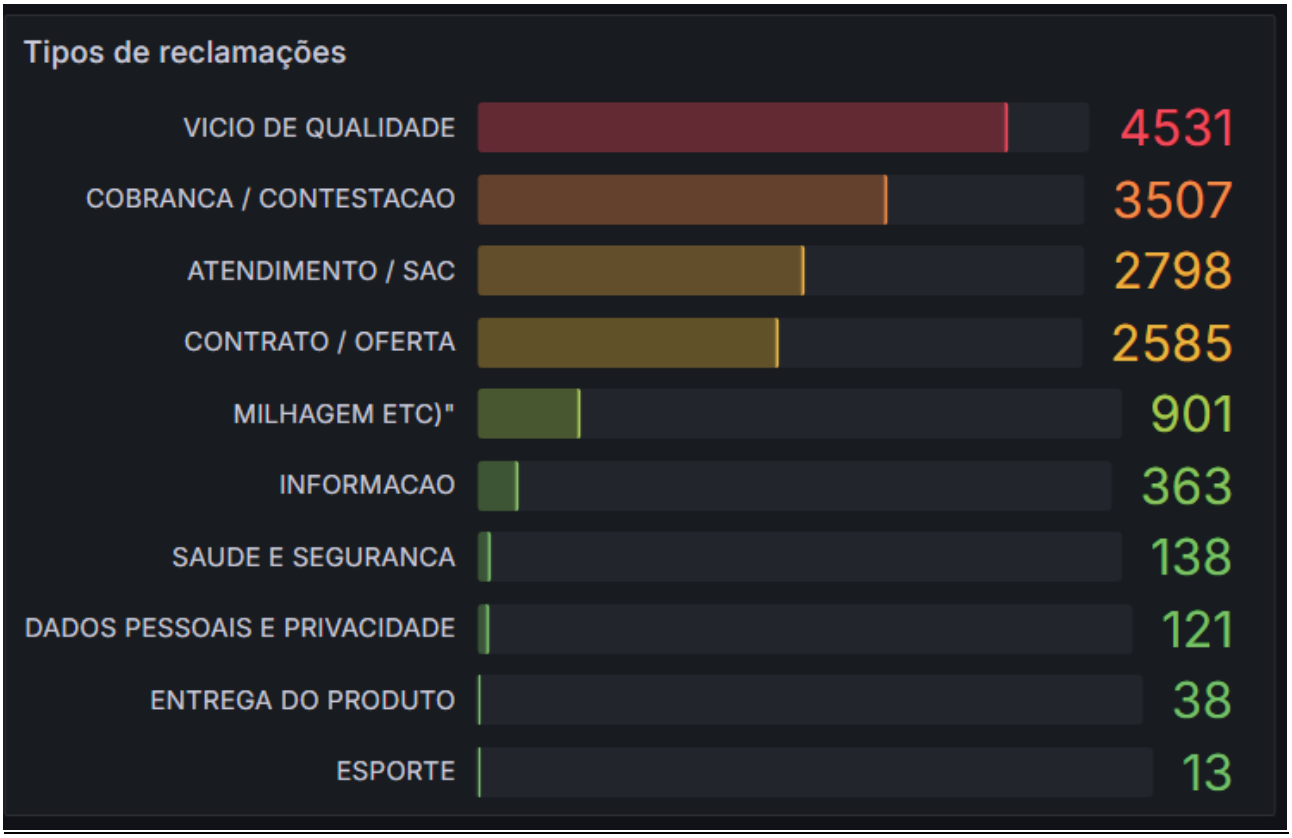
Tipos de reclamações
VICIO DE QUALIDADE 4531
COBRANCA / CONTESTACAO 3507
ATENDIMENTO / SAC 2798
CONTRATO / OFERTA 2585
MILHAGEM ETC)" 901
INFORMACAO 363
SAUDE E SEGURANCA 138
DADOS PESSOAIS E PRIVACIDADE 121
ENTREGA DO PRODUTO 38
ESPORTE 13

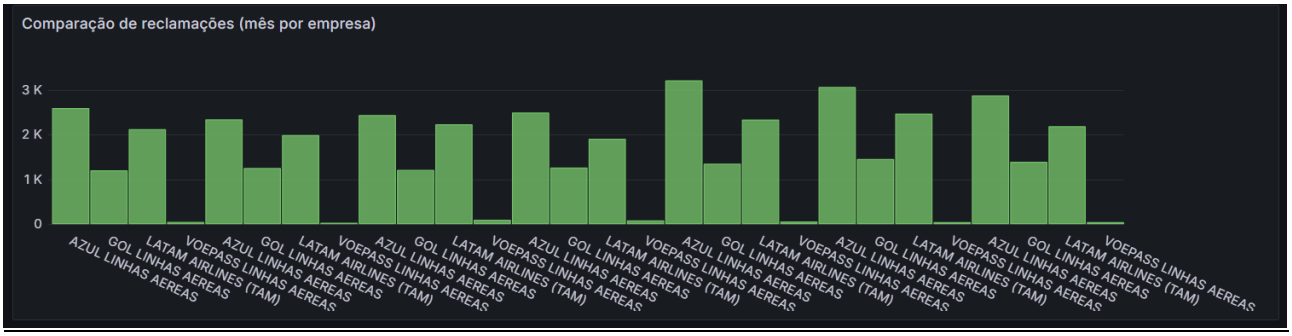

Snapshot da dashboard de reclamações:
https://snapshots.raintank.io/dashboard/snapshot/bY05HVZ06oHxy6UOyQqPVYbTKH4Nih4j

Código completo: https://github.com/Ivanrangelpm/analise-de-voos